

Laporan Praktikum Kontrol Cerdas Week 4

Nama : Rizky Surya Pratama
NIM : 224308045
Kelas : TKA-6B
Akun Github : <https://github.com/Suurya4>
Student Lab Assistant : Mas Dimas

1. Judul Percobaan: *Reinforcement Learning for Autonomous Control*
2. Tujuan Percobaan:
 - Memahami konsep dasar *Reinforcement Learning* (RL) dalam sistem kendali.
 - Mengimplementasikan agen RL menggunakan algoritma *Deep Q-Network* (DQN).
 - Menggunakan OpenAI *Gym* sebagai simulasi lingkungan untuk pelatihan RL.
 - Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
 - Menggunakan GitHub untuk *version control* dan dokumentasi praktikum.

3. Landasan Teori:

Reinforcement learning adalah belajar apa yang akan dilakukan pembelajaran dengan pemetaan situasi dalam menentukan Tindakan dan memaksimalkan angka sinyal penghargaan yang bisa diperoleh dari lingkungannya (Nguyen, et al., 2018). Tujuan *Reinforcement learning* yaitu menggunakan pengamatan yang dikumpulkan dari interaksi dengan lingkungan untuk mengambil tindakan yang akan memaksimalkan hasil dan meminimalkan risiko (Wijoyo , et al., 2024). Algoritma ini akan terus belajar secara iteratif. Pada algoritma ini terdapat agen yang akan belajar dari interaksi dengan lingkungannya. Untuk menghasilkan sebuah model, penguatan algoritma pembelajaran melalui beberapa tahapan, diantaranya agen mengamati data masukan, setelah itu agen mengambil tindakan untuk

mengambil keputusan. Setelah keputusan diambil, agen akan mendapatkan “reward” atau penguatan dari lingkungan. Kemudian mengamati input kembali dan proses pengambilan keputusan dilakukan kembali namun dengan tambahan penguatan dari lingkungan agar hasil keputusan yang diambil lebih akurat. Algoritma RL salah satunya DQN yang menggabungkan algoritma Q-Learning dengan Deep Neural Network (Fuad, 2022). Deep Q-Network (DQN) adalah algoritma dalam *Reinforcement Learning* (RL) yang menggunakan jaringan saraf dalam (*deep neural network*) untuk mendekati fungsi Q, yaitu fungsi yang memetakan keadaan (*state*) dan tindakan (*action*) ke nilai yang mengukur seberapa baik tindakan tersebut dalam jangka panjang. Q-Learning dikategorikan dalam metode model-free yang tidak membutuhkan informasi yang lengkap tentang kondisi Environment. Beberapa jenis environment yang digunakan dalam RL diantaranya LunarLander-v2, MountainCar-v0 dan cartpole.

4. Analisis dan Diskusi:

- Analisis

Pada percobaan yang telah dilakukan, diterapkan algoritma Deep Q-Network (DQN) dengan tujuan melatih agen dalam dua lingkungan yang berbeda, yaitu **LunarLander-V3** dan **CartPole-v1**. Pada **LunarLander-V3** Agen membantu mengurangi ketidakstabilan dalam pelatihan DQN dengan memperkenalkan jaringan duplikat yang diperbarui secara periodik. Tugas ini cukup menantang karena bobot target model diperbarui setiap 10 episode untuk menghindari osilasi selama pembelajaran. Reward diatur berdasarkan posisi, kecepatan, dan kondisi kaki saat pendaratan. Jika agen mendarat dengan aman di landasan, mendapat reward +100 hingga +200 poin. Jika agen jatuh atau keluar dari batas layer, mendapat penalty besar (-100 poin atau lebih). Pada awal pelatihan, agen lebih sering mengambil aksi secara acak (eksplorasi). Seiring waktu, agen mulai lebih sering memilih aksi terbaik berdasarkan nilai Q (eksploitasi). Pengalaman ini diambil secara acak saat pelatihan untuk meningkatkan generalisasi model guna membantu mengurangi osilasi dalam pembelajaran dengan

memperbarui nilai target secara berkala. Sedangkan pada **CartPole-v1** agen harus menjaga keseimbangan tiang di atas gerobak selama mungkin dengan menggerakkan gerobak ke kiri dan kanan untuk menghindari tiang jatuh. Agen mendapatkan reward untuk setiap langkah di mana tiang tetap seimbang, dan episode berakhir jika tiang jatuh atau batas waktu tercapai. Reward diatur berdasarkan kondisi lingkungan. Agen mendapatkan reward positif jika berhasil menjaga keseimbangan dan reward negatif jika tiang jatuh atau waktu habis. Dengan *epsilon decay* yang relatif cepat, agen lebih cepat beralih dari **eksplorasi** ke **eksploitasi**, yang mempercepat konsistensi pengambilan keputusan berdasarkan pengalaman sebelumnya.. Parameter seperti gamma (faktor diskon), epsilon (rate eksplorasi), dan epsilon_decay (penurunan epsilon) digunakan untuk pengambilan keputusan dan pembelajaran. batas maksimal episode 1000 membuat agen memiliki banyak kesempatan untuk belajar dan menyempurnakan kebijakan yang lebih optimal.

- Diskusi

Dari praktikum yang telah dilakukan dapat diketahui perbedaan hasil pembelajaran antara CartPole-v1 dan LunarLander-V3 menunjukkan bagaimana karakteristik lingkungan yang berbeda mempengaruhi cara agen belajar. Pada CartPole-v1, reward diberikan secara positif untuk setiap langkah yang sukses, agen mendapat reward secara kontinu, yang memberikan feedback langsung untuk memperbaiki kebijakan aksi. Hal ini mempercepat pelatihan dan memudahkan algoritma menemukan strategi yang baik. Ini membuat CartPole lebih mudah dipelajari dengan pendekatan eksplorasi yang lebih cepat dan replay buffer yang lebih kecil, karena agen mendapatkan pengalaman positif dengan lebih cepat. CartPole relatif sederhana sehingga cocok untuk eksperimen awal dalam reinforcement learning dan untuk menguji algoritma dasar seperti Q-learning atau DQN. Sebaliknya, di LunarLander-v3, Reward diberikan berdasarkan beberapa kondisi utama yang menentukan keberhasilan agen dalam mendaratkan pesawat luar angkasa dengan aman. Agen akan

mendapatkan reward positif ketika berhasil mendekati landasan dengan kecepatan yang sesuai, sementara reward negatif (penalti) diberikan jika agen bergerak terlalu cepat atau melenceng dari jalur optimal. Untuk mendorong efisiensi dalam penggunaan bahan bakar, setiap kali agen menyalakan thruster, ia akan dikenai penalti kecil. Jika agen berhasil mendarat dengan stabil di landasan, maka ia akan mendapatkan reward besar berkisar antara +100 hingga +200 poin, sedangkan jika pesawat jatuh atau keluar dari batas layar, agen akan menerima penalti besar sekitar -100 poin atau lebih. Selain itu, kondisi kaki pendarat juga mempengaruhi reward, di mana jika kedua kaki mendarat dengan stabil, agen mendapatkan bonus reward, tetapi jika hanya satu kaki yang menyentuh atau terjadi benturan keras, agen dikenai penalti. Dengan sistem reward ini, agen didorong untuk melakukan navigasi yang lebih aman, efisien, dan optimal dalam menyelesaikan tugasnya.

5. *Assignment:*

Pada praktikum minggu keempat ini, telah dilakukan implementasi dan perbandingan performa agen Deep Q-Network (DQN) pada dua lingkungan berbeda, yaitu CartPole-v1 dan LunarLander-v3 menggunakan pustaka OpenAI Gym dan TensorFlow. Agen DQN yang digunakan memiliki dua neural network utama, yaitu Q-Network untuk menentukan aksi optimal berdasarkan kondisi lingkungan dan Target Network yang diperbarui secara berkala untuk stabilisasi pelatihan. Selain itu, agen juga menerapkan Experience Replay menggunakan buffer untuk menyimpan pengalaman sebelumnya dan meningkatkan efisiensi pembelajaran.

Pada eksperimen pertama dengan CartPole-v1, agen bertugas menjaga keseimbangan tiang di atas gerobak/kotak selama mungkin. Agen mendapatkan reward +1 setiap langkah, sehingga umpan balik yang sering memungkinkan pembelajaran lebih cepat. Parameter seperti epsilon decay (0.995), replay buffer (2000), dan batch size (64) telah disesuaikan agar eksplorasi berkurang lebih cepat dan agen dapat fokus mengeksplorasi kebijakan yang sudah dipelajari. Hasil pelatihan menunjukkan bahwa agen







dapat meningkatkan skornya secara bertahap dan belajar menjaga keseimbangan tiang lebih lama seiring berjalannya waktu.



Sedangkan eksperimen kedua dilakukan pada LunarLander-v3, yang memiliki tantangan unik karena agen harus mengendalikan pendaratan pesawat luar angkasa di medan berbobot dengan gravitasi rendah. Tidak seperti CartPole, reward diberikan berdasarkan berbagai factor seperti posisi, kecepatan, penggunaan bahan bakar, dan stabilitas pendaratan, sehingga strategi eksplorasi dan control Gerakan menjadi lebih kompleks. Oleh karena itu, beberapa parameter diubah, seperti epsilon decay yang lebih lambat (0.999) untuk memungkinkan eksplorasi lebih lama, replay buffer yang lebih besar (5000) untuk menyimpan lebih banyak pengalaman, serta tambahan reward +100 hingga +200 saat agen berhasil mendarat dengan stabil. Perubahan ini bertujuan untuk memberikan agen lebih banyak kesempatan dalam menemukan kebijakan optimal sebelum memasuki fase eksploitasi. Dengan modifikasi tersebut, agen secara bertahap mampu menyesuaikan penggunaan thruster dan orientasi pendaratan agar dapat menyentuh landasan dengan aman meskipun membutuhkan Waktu lebih lama dibandingkan dengan CartPole.

Secara keseluruhan, tugas ini menunjukkan bagaimana pemilihan parameter dalam reinforcement learning sangat bergantung pada karakteristik lingkungan. Lingkungan dengan reward yang lebih sering, seperti CartPole, memungkinkan agen belajar lebih cepat dengan epsilon decay yang lebih cepat dan replay buffer yang lebih kecil. Sebaliknya, lingkungan dengan reward yang jarang seperti LunarLader-V3, membutuhkan eksplorasi yang lebih lama dan replay buffer yang lebih besar agar agen dapat mengumpulkan pengalaman yang cukup untuk menemukan strategi yang efektif.

6. Data dan Output Hasil Pengamatan:

No.	Variabel	Perbedaan	
		CartPole-v1	LunarLader-V3

1.	Waktu Pelatihan	CartPole lebih cepat mencapai performa optimal dalam beberapa ratus episode	LunarLander-V3 tetap membutuhkan lebih banyak waktu untuk mencapai keberhasilan yang stabil
2.	Jumlah Episode Maksimum	CartPole dilatih hingga 1000 episode 	MountainCar dilatih hingga 1000 episode 
3.	Skor Awal dan Maksimum	Skor bervariasi tergantung seberapa lama tiang tetap seimbang 	Skor mencapai 999 karena maksimal langkah dalam satu episode adalah 1000 
4.	<i>Epsilon</i>	Nilai epsilon (ε) menurun seiring dengan proses agen 	Nilai epsilon (ε) menurun seiring dengan proses agen 
5.	Kinerja Agen	Kinerja yang lebih stabil dengan skor yang lebih tinggi	Masih menghadapi tantangan dalam mencapai posisi terbaik

6.	Kondisi Berhasil	Episode berakhir jika tiang jatuh atau batas langkah maksimum tercapai	Episode berakhir jika agen berhasil mendarat dengan dua kaki tanpa terguling atau terpelant
7.	Hasil		

7. Kesimpulan:

Berdasarkan praktikum dan analisis yang telah dilakukan, maka dapat diambil kesimpulan yaitu:

- LunarLander-v3 lebih kompleks dibandingkan CartPole-v1 karena melibatkan kontrol posisi, kecepatan, dan penggunaan bahan bakar, serta memiliki sistem reward yang lebih beragam. Hal ini membuatnya cocok untuk menguji algoritma reinforcement learning yang lebih canggih.
- CartPole-v1 lebih sederhana dan cepat dipelajari, cocok untuk eksperimen awal dalam pengembangan algoritma pembelajaran penguatan, tetapi tidak memberikan tantangan besar untuk algoritma yang lebih kompleks.
- Agen menggunakan pendekatan DQN dengan replay buffer untuk memori, fungsi nilai Q di-*approximate* oleh jaringan saraf (*neural network*), dan *epsilon-greedy* untuk eksplorasi.
- Agen memulai dengan nilai epsilon tinggi (1.0) dan secara bertahap menurunkannya, memungkinkan agen untuk lebih banyak melakukan eksploitasi seiring dengan waktu.

8. Saran:

Untuk meningkatkan performa agen DQN dalam LunarLander-v3, beberapa perbaikan dapat diterapkan. Penggunaan Target Network dapat meningkatkan stabilitas pelatihan dan mencegah overfitting terhadap pola jangka pendek dengan cara memperbarui target network secara periodik. Selain itu, strategi epsilon decay yang lebih adaptif, seperti menyesuaikan nilai epsilon berdasarkan performa agen, dapat meningkatkan keseimbangan antara eksplorasi dan eksploitasi. Optimasi hyperparameter seperti gamma, learning

rate, dan epsilon decay juga diperlukan agar agen lebih cepat beradaptasi dan mencapai konvergensi yang stabil. Untuk menghindari masalah overestimation, penerapan Double DQN bisa menjadi solusi yang lebih baik dalam menentukan nilai optimal tindakan. Selain itu, metode Prioritized Experience Replay atau Actor-Critic Methods dapat digunakan untuk meningkatkan efisiensi pembelajaran dengan menyesuaikan strategi pengambilan keputusan agen berdasarkan reward yang diperoleh. Dengan perbaikan-perbaikan ini, diharapkan agen dapat belajar lebih cepat dan mencapai performa optimal dalam menyelesaikan tugas pendaratan dengan baik.

9. Daftar Pustaka

- Cahya, F., Riana, D. & Hadiyanti, S., 2021. Klasifikasi Penyakit Mata Menggunakan Convolutional Neural Network (CNN). *SISTEMASI*, p. 618.
- Fuad, M. R. T., 2022. Adaptive Deep Q-Network Algorithm with Exponential Reward Mechanisme for Traffic Control in Urban Intersection Networks. *Sustain*, Volume 14, p. 21.
- Malik, M., 2021. DETEKSI SUHU TUBUH DAN MASKER WAJAH DENGAN MLX90614, OPENCV, KERAS/TENSORFLOW, DAN DEEP LEARNING.. *Jurnal Engine: Energi, Manufaktur, dan Material*, p. 19.
- Nguyen, N. D., Nguyen, T. & Nahavandi, S., 2018. System Design Perspective for Human-Level Agent Using Deep Reinforcement Learning: A Survey. *IEEE Acces* , Volume 1, p. 99.
- Pumsirirat, 2018. Credit Card Fraud Detection using Deep Learning based on Auto-Encoder International Journal of Advanced. *ComputerScience and Applications (IJACSA)*, Volume 9(1), pp. 1825-1844.

Rahman, C. R. et al., 2020. Identification and recognition of rice diseases and pests using convolutional neural networks.. *Biosystems Engineering*, pp. 112-120.

Santoso, A. & Ariyanto, G., 2018. IMPLEMENTASI DEEP LEARNING BERBASIS KERAS UNTUK PENGENALAN WAJAH. *Jurnal Tekning Elektro*.

Wijoyo , A. et al., 2024. Pembelajaran Machine Learning. *Jurnal Ilmu Komputer dan Science*, Volume 3, p. 2.